

承诺书

我们完全清楚，在竞赛开始后参赛队员不能以任何方式，包括电话、电子邮件、“贴吧”、QQ 群、微信群等，与队外的任何人（包括指导教师）交流、讨论与赛题有关的问题；无论主动参与讨论还是被动接收讨论信息都是严重违反竞赛纪律的行为。

我们授权全国大学生数学建模竞赛组委会,可将我们的论文以任何形式进行公开展示(包括进行网上公示,在书籍、期刊和其他媒体进行正式或非正式发表等)。

参赛学校（完整的学校全称，不含院系名）：XX 大学

(指导教师签名意味着对参赛队的行为和论文的真实性负责)

(请勿改动此页内容和格式。此承诺书打印签名后作为纸质论文的封面，注意电子版论文中不得出现此页。以上内容请仔细核对，如填写错误，论文可能被取消评奖资格。)

赛区评阅编号：
(由赛区填写)

全国评阅编号：
(全国组委会填写)

2025 高教社杯全国大学生数学建模竞赛

编 号 专 用 页

赛区评阅记录（可供赛区评阅时使用）：

评 阅 人						
备 注						

送全国评阅统一编号：
(赛区组委会填写)

(请勿改动此页内容和格式。此编号专用页仅供赛区和全国评阅使用，参赛队打印后装订到纸质论文的第二页上。注意电子版论文中不得出现此页。)

全国大学生数学建模竞赛编写的 $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ 模板

摘要

关键字： $\text{T}_{\text{E}}\text{X}$ 图片 表格 公式

一、问题重述

1.1 问题背景

在生鲜商超运营中，蔬菜类商品因保鲜期短（多数品种当日未售出隔日无法再售）、品相随时间变差等特点，需每日根据历史销售与需求情况补货。商家并不确切知道具体单品和进货价格，而只能根据各商品的历史销售和需求情况进行每日的补货决策。因此记录商品的历史销售情况，挖掘蔬菜品类及单品间可能存在的关联关系，进而准确预测蔬菜各品类的销量是保障供应、控制成本和提升利润的关键。

由于蔬菜销售受季节、天气、节假日等多种复杂因素影响，且不同品类销售特性差异大，因此需要建立精准有效的销量预测模型。从需求侧看，蔬菜类商品的需求在时间上存在周期性，其需求与时间存在一定的关联性；从供给侧来看，蔬菜的种类供应和时间强相关，加之商超销售空间等限制使得合理的销售组合变得极为重要；结合两侧所需，可以分析各蔬菜品类的销售总量与成本定价之间的关系，从而进行合理的优化决策。

1.2 问题提出

下列问题层层递进，优先分析销售量的分布规律以及其相互关系，然后寻找定价与销售量的关系。紧接着，依据所发现的相互关系，将未来预测的销售量作为需求量，进而决定补货量和定价，实现收益最大化。

问题一：蔬菜类商品不同品类或不同单品之间可能存在一定的关联关系，请分析蔬菜各品类及单品销售量的分布规律及相互关系。

问题二：在对各蔬菜品类与单品销量分析的基础上，进一步分析决定各蔬菜品类市场需求的可能因素，从而确定不同的成本加成定价水平对市场需求的影响，并给出各蔬菜品类 2023 年 7 月 1-7 日的日补货总量和定价策略，使商超利益最大化；

问题三：在可售单品总数控制在 27-33 个，且各单品订购量满足最小陈列量 2.5 千克的前提下，尽量满足市场对各品类蔬菜商品的需求，同时根据 2023 年 6 月 24-30 日的可售单品，给出 7 月 1 日的单品补货量和定价策略。

问题四：结合以上问题的分析和建模过程，希望商家继续采集哪些相关数据，从而可以完善模型并更好地制定蔬菜商品的定价和补货决策。

二、问题分析

问题一：要求对蔬菜品类和单品的销售量进行统计，并分析其分布规律和相互关系。由于附件所给数据为时间序列数据，因此必须考虑时间效应，首先分析异常数据并进行

处理; 然后按照小时、日、周、月等时间单位来研究品类分布规律及变化趋势, 并进行类间占比分析; 研究每种品类内部单品的分布及变化规律, 进行类内单品占比分析; 研究不同品类所有单品的分布规律; 最后考虑使用相关系数、聚类分析等方法分析蔬菜品类间、单品间的相互关系.

问题二: 对应预测加优化的问题, 根据题目要求可分为两个小问. 首先计算各蔬菜品类日总销量与成本加成定价, 并给出两者的拟合函数关系; 然后利用时间序列模型对蔬菜品类的近期日销售量进行拟合, 进而预测未来一周的日销售量, 将其作为未来一周的需求量; 同时, 类似地, 对蔬菜品类的批发价格和加成率进行预测; 最后以日补货量和各品类每日销售单价为决策变量, 考虑损耗率、打折、日销量与成本加成定价之间的关系、日需求量等因素为约束条件, 建立使商超收益最大的约束优化模型, 并给出各品类未来一周的补货量与定价的具体结果.

问题三: 在问题二的基础上, 问题三以单品为对象, 针对未来 1 天的情况, 可售单品总数需控制在 27—33 个; 每个单品的订购量需满足最小陈列量 2.5 千克; 需“尽量满足各品类蔬菜的市场需求”(即单品补货量总和需接近该品类的预测需求量). 首先需要确定各品类中可替代或互补的单品, 例如可以通过相关性分析对各品类中的单品进行分类或聚类; 然后, 在考虑单品可替代性、互补性的前提下, 给出商品品种多样性的量化方法, 进而确定出满足商品陈列量和品种多样性约束的可售单品; 最后, 在问题二的基础上修改优化模型并求解.

三、模型假设与符号说明

3.1 模型假设

3.2 符号说明

四、问题一模型建立与求解

4.1 数据预处理

4.1.1 异常值处理

在附件内容没有明显缺失的情况下, 数据中可能出现异常值. 对具体的单品而言, 考虑到季节变化, 天气影响和送货环节异常等情况, 加之 2020—2023 年期间新冠疫情的存在, 上述内容可能使得部分蔬菜销量受到一定影响, 它们所造成的局部异常值, 极端值对统计销量和蔬菜相互关系以及后续预测蔬菜需求不具有普适性意义. 因此, 需要预处理异常值, 将其转化为可观测范围内的正常, 或直接舍弃.

依据附件 1 的“分类编码”字段, 将 251 个单品映射至六大品类(花菜类、食用菌、花叶类、辣椒类、茄类、水生根茎类). 采用箱线图处理异常值, 记各类别蔬菜的下四分位

点,中位数和上四分位点为 Q_1 , Q_2 , Q_3 ; 四分位距为 $IQR = Q_3 - Q_1$. 获取各单品蔬菜中超出正常分布区间的异常值, 异常值处理方法如下:

Step1 对附件 2 中全部”销量 (千克)” 字段按单品编码分别提取并排序, 计算第一四分位数 Q_1 与第三四分位数 Q_3 , 得到四分位距 $IQR_{1-3} = Q_3 - Q_1$ 。

Step2 稳健区间为

$$[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR]$$

落在区间外的观测记为异常. 对异常值进一步区分: 若异常发生于春节, 中秋和疫情封控等已知事件对应日期, 视为”可解释异常”, 予以保留; 其余异常视为”极端噪声”, 用该单品前后各 3 天正常销量的中位数进行替换, 以保证时间序列的连续性与季节性特征不被破坏.

Step3 将修正后的数据按日期重新对齐, 确保每条记录均包含单品编码, 销售日期和销量 (千克) 三列, 形成异常值已清洗的原始库.

以花菜类蔬菜为例, 三年总销量的日销售次数为纵轴, 星期属性为横轴, 绘制箱型图如下:




图 1 花叶类蔬菜日销量分布箱型图

4.1.2 数据清洗整合

首先, 以 “品类编码+销售日期” 为入口, 求出六类蔬菜的日均销量, 并利用箱线图对异常日销售量值剔除, 保留观测范围内的数值。再求出所有观测值的平均值, 并且用该平均值代替异常值, 中庸化处理以尽量减少未知因素对销量的异常影响。

对清洗后的销量进行汇总, 得到六大品类的日销量序列; 随后以 7 天为窗口滑动求和, 生成周销量序列; 以自然月为周期求和, 生成月销量序列。

按小时、日、周、月四种粒度整理数据:

(1) 小时级: 提取原始流水中的“销售时间”字段, 汇总 0-23 点逐小时的日均销量图, 用于日内波动分析;

(2) 日级: 每日品类销量, 覆盖 2020-07-01 至 2023-06-30 共 1095 d;

(3) 周级: 按 ISO 周历汇总, 共 157 周;

(4) 月级: 按自然月汇总, 共 36 个月.

下面以花叶类蔬菜为例, 展示其修复后的箱线图以及日均销量时间序列对比图。




图 2 修复后的花叶类蔬菜箱线图




图 3 修复后的花叶类蔬菜时间序列对比图

综合以上的内容, 我们可以显著地看到修复后的三年间花叶类蔬菜的箱线图异常值清零, 所有数据已经修复到可观测范围内; 日均销量时间序列图更加平顺, 极端值更少, 这说明我们的预处理是有效的。并且清洗后的数据不受极端值影响, 为我们后续挖掘相互关系提供了一定帮助。

4.2 销售量的分布规律

4.2.1 多时间粒度的类间销售量比较



在清洗后的数据基础上, 统计六大类别的蔬菜销售量占比. 花叶类总销量位于所有蔬菜品类销量之首, 占比达到 37.8%; 辣椒类和食用菌类的蔬菜占比分别达到 23.7% 和 16.9%; 花菜类、水生根茎类和茄类总销量占比较少。我们还需要得出具体的, 各品类的销售情况与相互关系. 由于附件所给数据为时间序列数据, 因此必须考虑时间效应, 兼顾精细化需求, 按月、日、小时不同的时间粒度, 绘制时间序列图。

部分蔬菜三年逐月销量如下。观察发现, 花菜类、花叶类、水生根茎类蔬菜在 4、5 月份销量较低, 花菜在春秋季节成熟较多, 辣椒多在 6-8 月成熟, 水生根茎类多于秋季成熟。销售旺季与其现实生活成熟季节有较大关联性, 可见蔬菜销售对时间的依赖性。




图 4 三年花菜类月均销量




图 5 三年辣椒类月均销量




图 6 三年水生根茎类月均销量

花叶蔬菜的三年总销量的日销量逐日分布折线比较图如下, 尽管 2022 年 1 月前后的日销量水平与 2021 年、2023 年同期水平相比较低, 该图仍然反映了一定的时间依赖性, 如: 花叶类蔬菜日销售量 1 月左右销量步入低潮、6 月后逐步销量步入升高。这与花叶类蔬菜本身的季节性、周期性有关。此外, 在销售中, 总是出现“锯齿状”的图样, 通过映射比较附件 2 中的日期数据, 发现节假日期间日销量会抬升, 周末总销量高于工作日, 反映出顾客集中采购行为增加; 工作日销量平稳, 各品类占比稳定。总之, 该图像反应花叶类销售呈现明显的时间依赖性, 适合构建单变量时间序列。




图 7 花叶类蔬菜三年每日销量统计折线图




图 8 部分品类蔬菜三年每日销量统计折线图（一）




图 9 部分品类蔬菜三年每日销量统计折线图（二）




图 10 部分品类蔬菜三年每日销量统计折线图（三）

为了验证、推广上述分析, 其他类别蔬菜的缩略图如下. 茄类、水生根茎、辣椒类、食用菌类蔬菜的三年总销量的日销量逐日分布折线比较图如上. 从图中可以看出, 其峰值节点、日销售量趋势变化均呈现规律排布. 蔬菜品类的日销量具有显著的时间依赖性, 构成单变量时间序列, 并表现出明显的季节性、周期性和节假日效应. 而且, 长期来看各个品类销售占比较为稳定, 因此, 可针对各品类的日销量序列, 采用时间序列建模方法对其变动趋势进行模拟与预测.




图 11 六类蔬菜每小时销量对比图

六类蔬菜的三年总销量的平均日销量逐小时分布折线比较图如上. 花叶类蔬菜从早上 8 点至晚上 10 点持续有销量、且销售量折线基本覆盖其他类别蔬菜, 说明该类蔬菜是民众三餐常备菜品. 整体来看, 所有菜品的销量在上午 10 点和下午 17 点达到峰值, 恰好对应于午餐和晚餐前的备菜高峰, 符合现实情况.

4.2.2 ARIMA 时间序列分析设计

ARIMA (自回归积分移动平均模型) 是时间序列分析中常用的预测模型, 适于处理非平稳时间序列数据. ARIMA 模型由三部分组成, 记为 $ARIMA(p,d,q)$, 其中:

(1) $AR(p)$ 自回归: 利用序列自身的滞后项 (过去值) 预测当前值, p 为滞后项数. 例如, $p=2$ 表示用前 2 期的值预测当前值.

(2) $I(d)$ 积分: 通过对非平稳序列进行 d 次差分, 使其转化为平稳序列, d 为差分次数 (通常 $d=0,1,2$).

(3) $MA(q)$ 移动平均: 关注自回归模型中误差项的累计, 利用序列的滞后误差项 (预测误差) 修正当前预测, q 为误差项的滞后项数.

根据需求分析维度, 以花叶类为例, 建立以周为时间粒度的近三个月销量序列, 以捕捉周内需求波动、周度工作日一周末差异及季节性产地转换效应.

建模流程如下:

Step1 检查时间序列的连续性、绘制时序图

Step2 平稳性检验, 若时序图显示非平稳 (有明显趋势), 需通过差分法通过 ADF 检验 (单位根检验)

Step3 基于平稳后的序列, 绘制 ACF (自相关函数) 图和 PACF (偏自相关函数) 图定阶




图 12 花叶类蔬菜销量 ACF 图

ACF 图用于衡量序列在不同滞后阶数下的线性相关性，反映序列当前值与过去值（滞后 k 期）的整体关联程度，主要用于确定 MA (q) 的阶数。在该图中，短期内滞后 1 期（即前 1 周）的自相关系数超出置信区间，显著不为 0, 说明近期销量对当前销量有直接影响（如上周销量高，本周可能延续趋势）。由于数据以周为粒度且存在周末 / 工作日差异，滞后 7 期、14 期等位置出现显著峰值，反映周度周期性，表明民众的每周消费模式相似。




图 13 花叶类蔬菜销量 PACF 图

PACF 图用于衡量序列在控制中间滞后项影响后，当前值与滞后 k 期值的净相关性，主要用于确定 AR (p) 的阶数。在该图中，滞后 1-2 期的偏自相关系数显著不为 0, 说明

在排除中间滞后项干扰后, 前 1-2 周对当前销量仍有直接影响, 支持自回归项 (AR) 的存在.

综上所述, 确定模型为 ARIMA (2,1,1).

上述主要阐明了 ARIMA 模型的 ACF 图, PACF 图及其指标确立, ARIMA 模型依据时间相关性, 进一步可以预测一定时间内的蔬菜需求量、加成率等内容. 在问题二中对预测内容有更详细的说明.

4.3 销售量的相互关系

4.3.1 品类间的 Pearson 和 Spearman 相关系数分析

为分析六大蔬菜品类 (花叶类、花菜类、水生根茎类、茄类、辣椒类、食用菌) 间的相互关系, 结合 Pearson 相关系数和 Spearman 等级相关系数, 从线性和单调两个维度量化品类间的关联性, 以识别互补或替代关系.

4.3.2 方法原理与适用性

1. **Pearson 相关系数**: 核心原理基于协方差与标准差, 衡量连续变量间的线性相关程度, 公式为:

$$r = \frac{Cov(X, Y)}{\sigma_x \cdot \sigma_y} \quad (1)$$

其中 $Cov(X, Y)$ 为协方差, σ_x 和 σ_y 分别为变量 X 和 Y 的标准差. 该方法适用于变量为连续型, 数据近似服从正态分布或样本量 $n > 30$, 且关系呈线性 (点图呈直线趋势) 的情况.

2. **Spearman 等级相关系数**: 核心原理基于秩次转换, 将数据按大小排序为等级, 衡量单调关系 (同增或同减趋势), 公式为:

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} \quad (2)$$

其中 d_i 为两变量秩次差, n 为样本量. 该方法适用于变量为连续型或有序分类 (如销量等级), 关系单调但非线性, 数据非正态或含异常值时更稳健.

4.3.3 分析流程设计

Step1 数据预处理: 聚合品类日销量数据, 缺失值以 0 填充 (无销售日), 异常值通过四分位距 (IQR) 法处理 (替换为均值); 标准化销量以消除量纲影响. 该步骤在 4.1 部分已经进行.

Step2 相关系数计算与检验: 分别计算日销量的 Pearson r 与 Spearman ρ . 反映短期波动关系.

Step3 显著性检验: 通过 t -检验 ($t = \frac{r(n-2)}{\sqrt{1-r^2}}$, 自由度 $df = n - 2$) 验证相关性, $P < 0.05$ 视为显著相关 (非随机误差).

Step4 通过下列准则确定关系:

- (1) 替代关系: 显著负相关 ($r < 0$ 或 $\rho < 0, p < 0.05$), 如辣椒类与花叶类竞争消费者预算;
- (2) 互补关系: 显著正相关 ($r > 0$ 或 $\rho > 0, p < 0.05$), 如花菜类与食用菌常搭配销售;
- (3) 无关性: $|r|$ 或 $|\rho|$ 接近 0 或 $p \geq 0.05$.

4.3.4 相关系数矩阵

品类	水生根茎	花叶类	花菜类	茄类	辣椒类	食用菌
水生根茎	1	0.42	0.38	-0.15	0.38	0.62
花叶类	0.42	1	0.60	0.37	0.66	0.61
花菜类	0.38	0.60	1	0.22	0.48	0.49
茄类	-0.15	0.37	0.22	1	0.22	-0.01
辣椒类	0.38	0.66	0.48	0.22	1	0.57
食用菌	0.62	0.61	0.49	-0.01	0.57	1

Pearson 相关系数矩阵

品类	水生根茎	花叶类	花菜类	茄类	辣椒类	食用菌
水生根茎	1	0.42	0.39	-0.19	0.33	0.61
花叶类	0.42	1	0.63	0.32	0.59	0.60
花菜类	0.39	0.63	1	0.24	0.43	0.46
茄类	-0.19	0.32	0.24	1	0.16	-0.09
辣椒类	0.33	0.59	0.43	0.16	1	0.53
食用菌	0.61	0.60	0.46	-0.09	0.53	1

Spearman 相关系数矩阵 通过上述两表分析, 可得出下列结论: 1. 花叶类蔬菜与其他类别蔬菜的相关系数整体较大, 表明花叶类与它们的正相关性较强。购买其他蔬菜时, 很有可能会购买花叶类蔬菜。

2. “食用菌、辣椒类和花叶类蔬菜”之间的相关系数的绝对值较大, 推测民众购买花叶类蔬菜时, 最有可能连带购买的是辣椒类和食用菌。商超可据此互补性搭配销售。

换言之，民众会选择固定的蔬菜搭配，如辣椒搭配花叶类蔬菜，两个系数矩阵表明部分蔬菜品类间具有较强的相关性；除此之外，相关系数低于 0.4, 可认为是二者之间的相关性并不明显。

3. 表中存在部分相关系数为负的情况，如食用菌和茄类，可认为二者销售时相关性近似于 0, 呈现为无关性。

4.4 单品聚类分析：群体特征与关系分组

4.4.1 方法原理与优势

核心原理: 采用 K-means 聚类算法, 通过最小化簇内平方误差 (SSE) 划分单品, 公式为:

$$SSE = \sum_{i=1}^K \sum_{x \in C_i} ||x - \mu_i||^2 \quad (3)$$

其中 μ_i 为第 i 个簇的质心, x 为数据点, 欧氏距离度量相似性:

$$d(x, y) = \sqrt{\sum (x_i - y_i)^2} \quad (4)$$

该方法可处理单品销量、价格、季节性指标等高维数据，通过分组降低复杂度, 识别隐性关联 (如“时令蔬菜群”), 弥补相关系数仅限两两关系的局限性, 揭示可能存在的“替代品群组”等全局结构。

4.4.2 分析流程设计

Step1 特征工程:

附件 1 共 251 种单品，如果对 251 个对象分簇不仅工程量大，而且难以满足我们寻找关系的需求。因此，选择最具有代表性的，销量最高的部分单品用以研究。

上图为 251 个单品中销量最高的 30 个单品，保留了原始单品代码，有助于我们聚类分析。按照附件 1 的映射关系可以得出，销量由高到低依次为“芜湖青椒 (1)”、“西兰花”、“净藕 (1)” ...

提取上述单品的特征 (月销量、年销量趋势、价格弹性), 并标准化以避免量纲偏差。

Step2 聚类步骤:

(1) 确定 K 值: 根据业务需求或肘部法, 本题目未提及商超的管理目标, 类群划分等要求在此根据肘部法得出 $K = 3$ 。肘部图如下。




图 14 前 30 个高销量单品销量占比饼图




图 15 聚类肘部图

(2) 初始化质心: 采用 $K - means++$ 算法优化, 确保质心分散;

(3) 迭代优化: 分配数据点 (计算单品到各质心的欧氏距离, 归入最近簇), 更新质心 (重算簇内均值作为新质心), 直至质心变化 $< \epsilon$ 或达最大迭代次数.

Step3 群体关系解析:

(1) 组内关系: 高相似单品可能互补, 如“叶菜群”中菠菜、油麦菜需求同增;

(2) 组间关系: 不同群可能替代, 如“茄果群”与“根茎群”竞争货架空间;

(3) 异常组: 独立群 (如珍稀食用菌), 与其他品类需求无关.

聚类结果、图示与评价指标数值如下。




图 16 单品聚类结果可视化图




图 17 聚类特征结果图

轮廓系数	DBI	CH
0.862	0.419	84.104

轮廓系数为 0.862，表明样本与所在簇的匹配度高，簇内样本相似度高且簇间差异明显。

DBI 通过计算簇内距离与簇间距离的比值来评估聚类质量，值越小表示聚类效果越好，说明簇内数据越紧凑且簇间差异越明显。CH 又称方差比准则，通过计算簇间离散度与簇内离散度的比值来评价聚类效果，值越大表示聚类效果越好，说明簇间差异越显著且簇内数据越集中。

综上所述，本次聚类效果较好。

各聚类统计特征如下：

Cluster	GroupCount	mean_kg	mean_money	std_money
1	5	1.0516	1.2309	4.1
2	20	0.45295	7.6285	1.6424
3	1	0.2174	19.194	5.0031

结合 4.3 和 4.4 的上述内容，可以进一步的推断出蔬菜品类、单品之间的相互关系。例如：销量第一的芜湖青椒 (1) 和销量第四的云南生菜分别属于“辣椒类”和“花叶类”相关系数表说明二者关联性较大，呈现互补关系。推测二者很有可能作为搭配被人们购买。

五、问题二模型建立与求解

5.1 建模过程

在问题二中，涉及到了六个蔬菜品类、未来七天的补货量与定价策略。现在使收益最大化，可做出收益的表达式为

$$\text{收益} = \text{销售量} \times \text{售价} - \text{补货量} \times \text{批发价}$$

在最理想的情况下 (即不浪费), 有

$$\text{需求量} = \text{销售量} = \text{进货量} \times (1 - \text{损耗率}) \times \text{折扣因素}$$

接下来按事情发展顺序符号化各个影响因素，并表示出约束条件。记第 i 个蔬菜类别在未来第 t 天的需求量为 $Q_{i,t}$, 补货量为 $S_{i,t}$, 对应的损耗率为 e_i , 预测的批发单价为 $C_{i,t}$, 那么此时到手的实际货物量为

$$S_{i,t}(1 - e_i).$$

之后，商家按照批发价格，设置销售单价为 $P_{i,t}$, 加成率为 $m_{i,t}$ 。由于定价是“成本加成”而来，有

$$P_{i,t} = C_{i,t}(1 + m_{i,t}).$$

在售卖中，考虑到商家会对部分商品采取优惠活动，记折扣系数为 δ_i 那么该类蔬菜在上述情况下最终的销量为

$$S_{i,t}(1 - e_i) \cdot \delta_i$$

理想情况下，有

$$S_{i,t}(1 - e_i) \cdot \delta_i = Q_{i,t}$$

各个变量汇总如下：

- $i = 1, \dots, 6$: 蔬菜品类编号
- $t = 1, \dots, 7$: 未来一周 (2023-07-01 至 2023-07-07) 的日期编号
- $Q_{i,t}$: 第 i 类蔬菜在第 t 天的需求量 (单位: kg)
- $P_{i,t}$: 第 i 类蔬菜在第 t 天的零售单价 (单位: 元/kg)
- $C_{i,t}$: 第 i 类蔬菜在第 t 天的批发单价 (单位: 元/kg)
- $S_{i,t}$: 第 i 类蔬菜在第 t 天的补货量 (决策变量, 单位: kg)
- $m_{i,t}$: 第 i 类蔬菜在第 t 天的成本加成率 (决策变量, 无量纲)
- δ_i : 第 i 类蔬菜的折扣系数 (由历史数据给定, 无量纲)
- e_i : 第 i 类蔬菜的损耗率 (由历史数据给定, 无量纲)
- $Q_{i,t}^{\min}, Q_{i,t}^{\max}$: 第 i 类蔬菜在第 t 天的最低、最高历史日销量 (单位: kg)
- $P_i^{\min}, P_i^{\max}$: 第 i 类蔬菜近三个月的最低、最高历史日销售单价 (单位: 元/kg)

其中, 损耗率 e_i 由附件 4 已知, 加成率 $m_{i,t}$, 折扣系数 δ_i 和需求量 $Q_{i,t}$ 需要根据历史数据进行预测.

5.2 销售总量与定价的关系

考虑到仅预测未来一周的情况, 选取最新三个月的数据训练方程即可. 首先, 利用花菜类数据来检验线性回归模型中的残差正态性假设. 结果如图所示.




图 18 回归标准化残差直方图

在线性回归模型中, 假设因变量 y 和自变量 x 之间存在线性关系, 即 $y = \beta_0 + \beta_1 x + \epsilon$, 其中 ϵ 是误差项 (残差)。残差正态性假设指的是, 这些误差项 ϵ 服从均值为 0 的正态分布。也就是说, 在给定自变量的条件下, 因变量的实际值与模型预测值之间的偏差, 应

该是随机且呈正态分布的。

在上述直方图中,横轴是回归标准化残差,纵轴是频率.如果残差确实服从正态分布,那么直方图的形状应该近似于一个钟形曲线(即正态分布曲线,图中叠加的黑色曲线就是正态分布的参考曲线).上图残差的分布出现一定的偏态情况,就意味着残差可能不满足正态性假设.

因此分别尝试线性回归模型、对数线性模型、其他非线性模型拟合,并且判断最优模型。

5.2.1 模型比较与最优拟合模型选择

为确定各蔬菜品类(对应数据集1至6)中销售总量(Sum_{Col4})与平均售价($4Mean_{Col5}$)的最优拟合模型,本节从解释力(R方、调整后R方)、预测精度(标准估算的错误)和模型显著性(F检验显著性)三个维度,对线性、对数、二次、三次、指数五种模型进行对比分析,着重介绍花菜类与花叶类的拟合方程确立。

评价指标说明 (1)R方(R^2):反映模型对因变量变异的解释比例,取值范围为 $[0,1]$,越接近1说明解释力越强.

(2)调整后R方(Adjusted R^2):修正了自由度对R方的影响,更适合比较不同复杂度的模型,优先选择更高值.

(3)标准估算的错误(MSE):衡量预测值与实际值的平均偏差,值越小说明预测精度越高.

(4)标准错误(SE):针对单个回归系数而言,衡量的是回归系数估计值的抽样波动程度.它反映了如果重复抽样、重新估计回归模型,该系数估计值会在多大范围内波动.数值越小,说明系数估计越稳定、可靠.

(5)显著性指标:利用t值或F值,检验模型整体有效性, $P < 0.05$ 说明模型显著(本文所有模型均满足 $P < 0.001$,整体显著).

模型对比结果

模型	R^2	调整后 R^2	标准估算的错误
线性	0.098	0.097	21.733
对数	0.095	0.094	21.769
二次	0.098	0.096	21.743
三次	0.098	0.095	21.753
指数	0.098	0.097	0.721

表 1 数据集 1 模型对比结果




图 19 数据集 1 不同模型拟合图

花菜类	结果	SE	t 值	F 值
系数	-2.865	0.264	-10.832	0.000
常数项	64.087	2.629	24.374	0.000
拟合方程	$y = 64.087 - 2.865 \cdot x$			

表 2 数据集 1 模型拟合结果

数据集 1(花菜类) 最优选择：线性模型

理由：线性模型与指数模型调整后 R 方最高 (0.097), 但线性模型在原始变量尺度下的标准误差 (21.733) 最小, 且模型形式简洁, 无额外高阶项, 解释性更强.

模型	R^2	调整后 R^2	标准估算的错误
线性	0.015	0.014	60.788
对数	0.016	0.015	60.741
二次	0.016	0.014	60.786
三次	0.035	0.033	60.207
指数	0.016	0.016	0.411

表 3 数据集 2 模型对比结果




图 20 数据集 2 不同模型拟合图

花叶类	结果	SE	t 值	F 值
系数 1	-213.053	43.410	-4.908	0.000
系数 2	32.672	6.858	4.764	0.000
系数 3	-1.642	0.351	-4.681	0.000
常数项	615.603	88.735	6.938	0.000
拟合方程 $y = 615.603 - 213.053 \cdot x + 32.672 \cdot x^2 - 1.642 \cdot x^3$				

表 4 数据集 1 模型拟合结果

数据集 2(花叶类) 最优选择：三次模型

理由: 三次模型调整后 R 方 (0.033) 显著高于其他模型, 标准估算的错误 (60.207) 最小, 对数据非线性特征的捕捉能力更强.

模型	R^2	调整后 R^2	标准估算的错误
线性	0.079	0.078	21.456
对数	0.085	0.084	21.383
二次	0.085	0.083	21.390
三次	0.090	0.088	21.338
指数	0.072	0.071	0.855

表 5 数据集 3 模型对比结果

数据集 3(水生根茎类) 最优选择: 三次模型

理由: 三次模型调整后 R^2 (0.088) 最高, 标准估算的错误 (21.338) 最小, 较对数和二次模型进一步提升了解释力和预测精度.

模型	R^2	调整后 R^2	标准估算的错误
线性	0.065	0.064	25.392
对数	0.063	0.062	25.411
二次	0.066	0.064	25.389
三次	0.074	0.071	25.294
指数	0.065	0.064	0.400

表 6 数据集 4 模型对比结果

数据集 4(辣椒类) 最优选择: 三次模型

理由: 三次模型调整后 R^2 (0.071) 最高, 标准估算的错误 (25.294) 最小, 对变量间非线性关系的拟合效果最优.

模型	R^2	调整后 R^2	标准估算的错误
线性	0.062	0.061	8.622
对数	0.062	0.061	8.621
二次	0.065	0.063	8.611
三次	0.079	0.076	8.550
指数	0.038	0.037	0.561

表 7 数据集 5 模型对比结果

数据集 5(茄类) 最优选择: 三次模型

理由: 三次模型调整后 R 方 (0.076) 显著高于其他模型, 标准估算的错误 (8.550) 最小, 对数据趋势的捕捉更精准.

模型	R^2	调整后 R^2	标准估算的错误
线性	0.070	0.069	23.345
对数	0.061	0.060	23.465
二次	0.077	0.076	23.267
三次	0.093	0.090	23.083
指数	0.074	0.073	0.473

表 8 数据集 6 模型对比结果

数据集 6(食用菌类) 最优选择: 三次模型

理由: 三次模型调整后 R 方 (0.090) 最高, 标准估算的错误 (23.083) 最小, 对非线性关系的拟合效果优于其他模型.

5.2.2 总结

除花菜类更适合线性模型外, 花叶类、水生根茎类、辣椒类、茄类、食用菌类均以三次模型为最优拟合模型, 其对变量间非线性关系的捕捉能力更强, 整体解释力和预测精度更优. 各蔬菜品类的最优拟合模型及其拟合方程汇总如下表所示:

蔬菜品类	对应数据集	最优模型	核心优势
花菜类	数据集 1	线性模型	解释力强, 形式简洁, 原始尺度预测精度高
花叶类	数据集 2	三次模型	调整后 R 方最高, 标准误差最小, 捕捉非线性特征
水生根茎类	数据集 3	三次模型	解释力和预测精度最优
辣椒类	数据集 4	三次模型	对非线性关系拟合效果最佳
茄类	数据集 5	三次模型	显著提升解释力和预测精度
食用菌类	数据集 6	三次模型	调整后 R 方最高, 预测偏差最小

表 9 各蔬菜品类最优模型汇总

蔬菜品类	销售量与定价的拟合方程
花菜类	$y = 64.087 - 2.865 \cdot x$
花叶类	$y = 615.603 - 213.053 \cdot x + 32.672 \cdot x^2 - 1.642 \cdot x^3$
水生根茎类	$y = 136.155 - 24.900 \cdot x + 1.903 \cdot x^2 - 0.050 \cdot x^3$
辣椒类	$y = 50.698 + 13.153 \cdot x - 1.838 \cdot x^2 + 0.066 \cdot x^3$
茄类	$y = -1.992 + 10.182 \cdot x - 1.331 \cdot x^2 + 0.050 \cdot x^3$
食用菌类	$y = -134.104 + 51.550 \cdot x - 4.312 \cdot x^2 + 0.110 \cdot x^3$

表 10 销售量与定价的拟合方程汇总

上述为日销售量与定价的关系求解，折扣系数的求解与之类似，将研究对象替换为“打折的单品”，并且求出每一类打折商品销量占据总商品销量的比例，计算每一类商品打折的平均值。

将“未打折部分的商品”和“打折后的商品”作比较，求出其销量与售价的函数关系，进而得出打折后对其销量的影响力。记 a 为折扣比例， b 为平均折扣。所得结果如下表。

蔬菜品类	打折比例	平均折扣	折扣系数
花菜类	0.054	0.64	0.98
花叶类	0.068	0.60	0.97
水生根茎类	0.090	0.77	0.98
辣椒类	0.060	0.58	0.97
茄类	0.027	0.72	0.99
食用菌类	0.083	0.54	0.96

表 11 各品类蔬菜的折扣系数汇总

5.3 构建最优化模型

5.3.1 模型引入

根据 5.1 建模过程，需要根据历史数据对加成率 $m_{i,t}$ ，和需求量 $Q_{i,t}$ 预测。下面介绍相关预测模型。

(1) 广义加性模型 (GAM)

以 7 天为周期构造周期样条基函数，捕捉销量对价格、时间、加成率等的非线性关系：

$$\log Q_{i,t} = \beta_{i,0} + f_{i,1}(\log P_{i,t}) + f_{i,2}(t) + f_{i,3}(m_{i,t}) + \varepsilon_{i,t}, \quad (5)$$

其中 $f_{i,\cdot}(\cdot)$ 为光滑函数（周期样条）， $\varepsilon_{i,t}$ 为 GAM 残差。

(2)ARIMA 残差修正对残差序列 $\{\varepsilon_{i,t}\}$ 建立 ARIMA(p, d, q) 模型:

$$\Phi_i(L)(1-L)^d \varepsilon_{i,t} = \Theta_i(L)\eta_{i,t}, \quad \eta_{i,t} \sim \mathcal{N}(0, \sigma_{\eta,i}^2), \quad (6)$$

其中 L 为滞后算子, $\Phi_i(L)$ 、 $\Theta_i(L)$ 分别为自回归与滑动平均多项式.

(3) 组合预测将 GAM 主趋势与 ARIMA 残差预测叠加, 得到最终销量预测:

$$\hat{Q}_{i,t} = \exp \left[\widehat{\log Q_{i,t}}^{\text{GAM}} + \hat{\varepsilon}_{i,t}^{\text{ARIMA}} \right]. \quad (7)$$

上述为需求量的预测方法, 加成率 $m_{i,t}$ 可以简化预测模型, 仅采用 ARIMA 模型预测.

5.3.2 收益最大化模型

目标函数 未来一周总收益最大化:

$$\max_{\{S_{i,t}, m_{i,t}\}} \sum_{i=1}^6 \sum_{t=1}^7 \left[Q_{i,t} P_{i,t} - S_{i,t} C_{i,t} \right], \quad (8)$$

其中

- $Q_{i,t}$ 由 (7) 给出;
- $P_{i,t} = C_{i,t}(1 + m_{i,t})$;
- 需求量与补货量、损耗、折扣之间的关系:

$$Q_{i,t} = S_{i,t}(1 - e_i)\delta_i. \quad (9)$$

将 (9) 代入 (8), 消去 $Q_{i,t}$, 得到仅以决策变量 $S_{i,t}, C_{i,t}$ 表示的目标函数:

$$\max_{\{S_{i,t}, m_{i,t}\}} \sum_{i=1}^6 \sum_{t=1}^7 \left[S_{i,t}(1 - e_i)\delta_i C_{i,t}(1 + m_{i,t}) - S_{i,t} C_{i,t} \right]. \quad (10)$$

约束条件

1. 销量可行域:

$$Q_{i,t}^{\min} \leq S_{i,t}(1 - e_i)\delta_i \leq Q_{i,t}^{\max}, \quad \forall i, t.$$

2. 定价可行域:

$$P_i^{\min} \leq C_{i,t}(1 + m_{i,t}) \leq P_i^{\max}, \quad \forall i, t.$$

3. 非负补货:

$$S_{i,t} \geq 0, \quad \forall i, t.$$

4. 加成率上下限（可根据业务经验设定）：

$$m_i^{\min} \leq m_{i,t} \leq m_i^{\max}, \quad \forall i, t.$$

5.4 求解步骤

1. 步骤 1: 使用历史数据估计 GAM (5) 与 ARIMA (6)，得到 $\hat{Q}_{i,t}$.
2. 步骤 2: 将 $\hat{Q}_{i,t}$ 代入 (9) 反解 $S_{i,t}$ ，作为初始可行解.
3. 步骤 3: 以 (10) 为目标，在约束条件下进行非线性规划（如 SQP 或遗传算法），得到最优 $\{S_{i,t}^*, m_{i,t}^*\}$.
4. 步骤 4: 输出未来一周各品类的日补货量 $S_{i,t}^*$ 与定价策略 $P_{i,t}^* = C_{i,t}(1 + m_{i,t}^*)$.

下面以花叶类蔬菜为例，首先，利用近三年日销售量数据训练 GAM-ARIMA 复合模型做出日销售量的拟合图，其 ACF, PACF, 残差检验方法同 4.2.2 中的时间序列模型. 并利用该模型预测未来 7 天的需求量，给出可能的需求量初始解，再利用式 (9) 反解出可能的补货量初始解. 各类蔬菜的预测需求量汇总如下.




图 21 三年花叶类日销售量 GAM-ARIMA 拟合情况

蔬菜品类	7月1日	7月2日	7月3日	7月4日	7月5日	7月6日	7月7日
花菜类	23.39	21.85	20.82	21.90	22.90	23.64	24.82
花叶类	123.51	126.53	126.65	139.85	148.07	140.84	142.87
水生根茎类	21.44	20.00	20.96	20.63	21.00	20.97	21.17
辣椒类	79.59	80.16	80.47	82.16	81.78	84.42	86.32
茄类	23.09	22.17	18.85	20.15	19.47	22.07	21.80
食用菌类	43.15	46.19	49.56	53.95	53.38	52.73	50.84

表 12 各品类的预计需求量初始解

加成率利用 ARIMA 模型进行预测，类似于销售量的预测方法，在此不再赘述，仅说

明其检验结果与预测结果. 拟合的 R^2 为 0.98, 均方根误差 (RMSE) 为 0.019, 数值较小, 说明拟合效果很好. 可以作为有效的模型采纳, 并进行后续的预测工作.




图 22 三年花叶类加成率 ARIMA 拟合情况




图 23 三年花叶类加成率残差的 ACF 与 PACF 图

蔬菜品类	7月1日	7月2日	7月3日	7月4日	7月5日	7月6日	7月7日
花菜类	0.472	0.468	0.499	0.498	0.517	0.525	0.526
花叶类	0.575	0.586	0.570	0.578	0.587	0.593	0.599
水生根茎类	0.241	0.251	0.262	0.262	0.262	0.262	0.262
辣椒类	0.573	0.602	0.613	0.614	0.615	0.616	0.617
茄类	0.674	0.654	0.639	0.633	0.629	0.625	0.621
食用菌类	0.518	0.517	0.520	0.521	0.520	0.522	0.521

表 13 各品类的预计加成率

在获得了平均损耗率 e_i , 折扣系数 δ_i , 预测的加成率 $m_{i,t}$, 和需求量 $Q_{i,t}$ 后, 可以对 5.3 的收益最大化模型采取遗传算法求解.

依据式 (10), 将 $S_{i,t}, C_{i,t}$ 作为决策变量,

统计依据近三个月的最低、最高历史日销售单价 P_i^{min}, P_i^{max} 限制各类蔬菜定价 $P_{i,t}$ 在以下范围内 (该限制是一个软约束, 亦即优化结果应当尽量在该范围内, 允许局部数值越界), 已知

$$P_{i,t} = C_{i,t} \cdot (1 + m_{i,t})$$

那么可预计批发价的范围 $[C_{min}, C_{max}]$ 由下式表示.

$$C_{min} = \frac{P_{min}}{1+m}$$

$$C_{max} = \frac{P_{max}}{1+m}$$

蔬菜品类	$P_{i,t}^{max}$	$P_{i,t}^{min}$
花菜类	15.2	9.23
花叶类	7.54	4.29
水生根茎类	19.00	7.53
辣椒类	9.71	5.51
茄类	9.79	6.00
食用菌类	13.99	6.98

表 14 各品类的批发价限制范围

下面针对问题二适配设计遗传算法

Step1 对决策变量编码

将每一天每一个品类的 S 和 C 按顺序拼接为一维向量, 作为遗传算法的“染色体”。

Step2 初始种群生成

补货量 S 的初始值基于需求量预测 Q 调整, 确保初始解贴近实际需求.

$$S_{i,t} = \frac{Q_{i,t}}{(1 - e_i) \cdot \delta_i}$$

批发价 C 的初始值在 $[C_{min}, C_{max}]$ 范围内随机生成, 满足定价约束.

Step3 适应度函数 (目标函数)

由于遗传算法默认最小化目标, 将“总收益”取负值作为优化目标 (即算法最小化“- 总收益”, 等价于最大化总收益)。

Step4 设置约束

通过“不等式约束函数”确保零售价 P 在 $[P_{min}, P_{max}]$ 范围内; 通过变量上下界确保 S 和 C 在合理范围。

Step4 终止条件

在平衡求解效率与精度考虑下, 设置最大迭代代数 200.

最终优化结果如下

表 15 最优补货量 $S_{i,t}$

蔬菜品类	7月1日	7月2日	7月3日	7月4日	7月5日	7月6日	7月7日
花菜类	38.5855	33.9599	34.4547	35.2427	42.3419	41.9302	36.3043
花叶类	174.5648	162.0841	166.2129	187.1118	180.3496	180.8037	186.5230
水生根茎类	103.8277	108.1377	104.0349	105.9744	113.0782	109.5558	107.4384
辣椒类	34.5861	38.6752	33.1396	31.9475	34.6954	34.4405	38.9036
茄类	66.8161	67.9106	67.8323	77.8484	70.6682	76.3470	65.6313
食用菌类	27.0060	28.1633	28.3786	29.9972	26.3494	34.8950	30.9244

表 16 估计批发价 $C_{i,t}$

蔬菜品类	7月1日	7月2日	7月3日	7月4日	7月5日	7月6日	7月7日
花菜类	10.3180	10.2356	9.8392	10.1440	9.8934	9.5305	9.8157
花叶类	4.7132	4.6592	4.7074	4.7670	4.7484	4.6934	4.6861
水生根茎类	6.1363	6.0257	5.9484	5.8724	6.0048	5.9663	5.9250
辣椒类	5.6349	5.7602	5.8220	5.8778	5.7737	5.9963	5.9431
茄类	9.1804	9.0114	8.9700	9.1337	9.1773	9.0440	9.1004
食用菌类	15.3033	14.5968	15.0112	14.3743	14.9915	14.2048	14.3989

表 17 最优定价 $P_{i,t}$

蔬菜品类	7月1日	7月2日	7月3日	7月4日	7月5日	7月6日	7月7日
花菜类	15.1850	15.0248	14.7440	15.1926	15.0073	14.5321	14.9749
花叶类	7.4228	7.3876	7.3916	7.5228	7.5372	7.4774	7.4907
水生根茎类	9.6530	9.6502	9.5959	9.4787	9.6983	9.6415	9.5807
辣椒类	9.4318	9.5280	9.5393	9.6008	9.4047	9.7433	9.6355
茄类	13.9385	13.6739	13.5390	13.9323	13.9513	13.7686	13.8436
食用菌类	18.9945	18.2533	18.9442	18.1404	18.9193	17.9250	18.1699

表 18 最优销量 $Q_{i,t}$

蔬菜品类	7月1日	7月2日	7月3日	7月4日	7月5日	7月6日	7月7日
花菜类	31.9717	28.1389	28.5490	29.2019	35.0842	34.7431	30.0815
花叶类	148.0596	137.4739	140.9758	158.7015	152.9661	153.3512	158.2021
水生根茎类	91.8593	95.6725	92.0506	93.7585	100.0435	96.9271	95.0538
辣椒类	32.0337	35.8210	30.7439	29.5898	32.1349	31.8988	36.0326
茄类	58.1787	59.1317	59.0366	67.7848	61.5328	66.4775	57.1470
食用菌类	22.8370	23.8156	23.9976	25.3664	22.2818	29.5081	26.1505

表 19 最大总收益等信息

最大总收益: 6925.8589
约束验证: 补货量约束满足、定价约束满足、批发价与加成率关系约束满足

六、问题三模型建立与求解

商超需制定 7 月 1 日蔬菜单品补货计划, 核心目标为: 在可售单品总数控制在 27-33 个、各单品订购量不低于 2.5kg 的约束下, 通过合理选择单品及制定定价策略, 最大化收益并尽量满足市场需求.

与前期问题相比, 本问题聚焦”单品级”优化, 需通过聚类分析挖掘单品替代关系, 筛选核心单品, 同时构建收益最大化模型并满足约束条件.

6.1 数据预处理与聚类分析

6.1.1 数据基础

基于 2023 年 6 月 24-30 日可售单品数据, 提取关键指标: 日均销量、毛利率、损耗率、价格区间 (最低/最高单价) 等, 为聚类及优化模型提供参数支持.

6.1.2 K-means 聚类分组

为实现 “品类-替代关系” 分组, 采用 K-means 聚类算法对单品进行分组, 核心步骤如下:

最佳聚类数确定 通过肘部法则分析聚类误差随聚类数的变化趋势 (见图24), 当聚类数为 4 时, 误差曲线出现明显拐点, 结合聚类评价指标 (轮廓系数、IDBI、ICH) 验证 (见表20), 确定最佳聚类数为 4.




图 24 肘部法则确定最佳聚类数

聚类评价与统计特征 聚类结果的评价指标及各簇统计特征如下表所示, 各簇在特征 (C、D、E、X) 上呈现显著差异, 为替代关系分析提供依据.

自动确定的最佳聚类数: 4

聚类评价指标结果:

轮廓系数	DBI	CH
0.580	0.717	30.725

各聚类统计特征:

	Cluster	GroupCount	mean_C	std_C	mean_D	std_D	mean_E	std_E	mean_x__	std_x__
1	1	11	0.41442	0.16317	17.515	4.7529	12.441	2.9684	12.629	7.2229
2	2	13	0.46883	0.12867	4.2356	1.3129	2.9035	0.91489	7.2454	5.5257
3	3	18	0.66013	0.14797	6.5436	2.7602	3.9776	1.6803	9.3622	3.9856
4	4	1	1.3857	0	5.6965	0	2.4706	0	9.43	0

表 20 聚类评价指标及各聚类统计特征

聚类相似度与分布特征 -相似度矩阵 (图25) 显示簇间相似度差异, 其中簇 1 与簇 4 相似度最低 (-0.5431), 簇 2 与簇 3 存在一定正向关联 (0.2344), 说明簇内单品替代关系更强.

-PCA 降维可视化 (图26) 直观展示 4 个聚类中心的分布, 第一主成分解释 58.7% 的方差, 各簇在空间上分离明显.

-平行坐标图 (图27) 展示各特征 (B、C、D、E) 在不同聚类中的分布趋势, 簇 1 在特征 C、D 上值较高, 簇 2 在特征 B 上表现突出, 说明簇 1 单品替代关系更强.




图 25 4 类聚类相似度矩阵




图 26 品类聚类结果 (PCA 降维)




图 27 平行坐标图-聚类特征分布

单品分组筛选 根据聚类结果 (见表21), 每组保留 1-2 个高毛利 + 高销量单品, 优先覆盖 6 大品类, 最终筛选出 30 个单品 (满足 $27 \leq n \leq 33$ 约束).

表 21 聚类分组及单品筛选示例

Cluster	代表单品	核心特征	保留单品
1	七彩椒、洪湖藕带	特征 C、D 值高	七彩椒、洪湖藕带、枝江青梗散花
2	云南油麦菜、菠菜	特征 B 值较高	云南油麦菜、菠菜、娃娃菜
3	奶白菜、姜蒜小米椒组合装	特征 C 中等、毛利率高	奶白菜、小青菜、木耳菜
4	小米椒 (份)	特征 B 值极高	小米椒 (份)

6.2 优化模型建立

6.2.1 目标函数

以商超总收益最大化为目标，收益计算公式为：

$$\max = \sum_{i=1}^n \left[(k \cdot f(p) + C) P_i - \frac{1}{1 + \gamma_i} S_i P_i \right]$$

其中：(1) P_i 为第 i 个单品的销售单价， S_i 为补货量；

(2) γ_i 为加成率， $f(p)$ 为价格影响函数， $k \square C$ 为常数系数；

(3) 第一项为销售收入，第二项为成本支出。

6.2.2 约束条件

1. 补货量约束: $S_i \geq 2.5 \text{ kg}$ (最小陈列量要求);
2. 单品总数约束: $27 \leq n \leq 33$;
3. 价格区间约束: $P_{\min,i} \leq P_i \leq P_{\max,i}$ (基于 6 月历史价格);
4. 需求匹配约束: $\min(Q_{\min,i}, 2.5 \text{ kg}) \leq (1 - \theta_i) S_i \leq R_i$ ，其中 θ_i 为损耗率， R_i 为需求量， $Q_{\min,i}$ 为历史最低销量。

6.2.3 求解步骤

1. 基于聚类结果确定 30 个入选单品，覆盖全部 6 大品类;
2. 代入历史数据计算各单品参数 ($R_i \square \gamma_i \square \theta_i \square P_{\min,i} \square P_{\max,i}$);
3. 通过线性规划求解目标函数，确定各单品的补货量 S_i 和定价 P_i 。

6.3 核心结果

(1) 入选单品: 30 个 (如七彩椒、云南油麦菜、奶白菜等)，满足品类全覆盖及数量约束;

(2) 补货量: 所有单品 $S_i \geq 2.5 \text{ kg}$ ，高需求单品 (如小米椒) 补货量达 10kg 以上;

(3) **定价策略**: 单价均在历史最低与最高价格区间内, 高毛利单品 (如姜蒜组合装) 定价接近上限, 促销单品 (如海鲜菇) 定价接近下限.

本方案通过 **K-means** 聚类实现单品科学分组, 结合优化模型确定补货量与定价, 在满足约束条件的前提下最大化收益, 同时保障了市场需求的覆盖. 聚类分析结果为单品筛选提供了数据支撑, 模型求解结果可直接用于 7 月 1 日的补货执行.

七、问题四模型建立与求解

参考文献

- [1] 刘海洋. $\text{\LaTeX}$ 入门[J]. 电子工业出版社, 北京, 2013.
- [2] 全国大学生数学建模竞赛论文格式规范 (2023 年修改).
- [1] <https://www.latexstudio.net>

附录 A 模板所用的宏包

表 22 宏包罗列

模板中已经加载的宏包				
amsbsy	amsfonts	amsgen	amsmath	amsopn
amssymb	amstext	appendix	array	atbegshi
atveryend	auxhook	bigdelim	bigintcalc	bigstrut
bitset	bm	booktabs	calc	caption
caption3	CJKfntef	cprotect	ctex	ctexhook
ctexpatch	enumitem	etexcmds	etoolbox	everyssel
expl3	fix-cm	fontenc	fontspec	fontspec-xetex
geometry	getttitlestring	graphics	graphicx	hobsub
hobsub-generic	hobsub-hyperref	hopatch	hxetex	hycolor
hyperref	ifluatex	ifpdf	ifthen	ifvtex
ifxetex	indentfirst	infwarerr	intcalc	keyval
kvdefinekeys	kvoptions	kvsetkeys	l3keys2e	letltxmacro
listings	longtable	lstmisc	ltxcaption	ltxcmds
multirow	nameref	pdfescape	pdftexcmds	refcount
rerunfilecheck	stringenc	suffix	titletoc	tocloft
trig	ulem	uniquecounter	url	xcolor
xcolor-patch	xeCJK	xeCJKfntef	xeCJK-listings	xparse
xtemplate	zhnumber			

以上宏包都已经加载过了，不要重复加载它们。

附录 B 排队算法—matlab 源程序

```

kk=2; [mdd, ndd]=size(dd);
while ~isempty(V)
    [tmpd, j]=min(W(i, V)); tmpj=V(j);
    for k=2:ndd
        [tmp1, jj]=min(dd(1, k)+W(dd(2, k), V));
        tmp2=V(jj); tt(k-1, :)= [tmp1, tmp2, jj];
    end
    tmp= [tmpd, tmpj, j; tt]; [tmp3, tmp4]=min(tmp(:, 1));
    if tmp3==tmpd, ss(1:2, kk)= [i; tmp(tmp4, 2)];
    else, tmp5=find(ss(:, tmp4)~=0); tmp6=length(tmp5);

```

```

if dd(2,tmp4)==ss(tmp6,tmp4)
ss(1:tmp6+1,kk)=[ss(tmp5,tmp4);tmp(tmp4,2)];
else, ss(1:3,kk)=[i;dd(2,tmp4);tmp(tmp4,2)];
end;end
dd=[dd,[tmp3;tmp(tmp4,2)]];V(tmp(tmp4,3))=[];
[mdd,ndd]=size(dd);kk=kk+1;
end; S=ss; D=dd(1,:);

```

附录 C 规划解决程序—lingo 源代码

```

kk=2;
[mdd,ndd]=size(dd);
while ~isempty(V)
    [tmpd,j]=min(W(i,V));tmpj=V(j);
for k=2:ndd
    [tmp1,jj]=min(dd(1,k)+W(dd(2,k),V));
    tmp2=V(jj);tt(k-1,:)= [tmp1,tmp2,jj];
end
    tmp=[tmpd,tmpj,j;tt];[tmp3,tmp4]=min(tmp(:,1));
if tmp3==tmpd, ss(1:2,kk)=[i;tmp(tmp4,2)];
else,tmp5=find(ss(:,tmp4)~=0);tmp6=length(tmp5);
if dd(2,tmp4)==ss(tmp6,tmp4)
    ss(1:tmp6+1,kk)=[ss(tmp5,tmp4);tmp(tmp4,2)];
else, ss(1:3,kk)=[i;dd(2,tmp4);tmp(tmp4,2)];
end;
end
    dd=[dd,[tmp3;tmp(tmp4,2)]];V(tmp(tmp4,3))=[];
    [mdd,ndd]=size(dd);
    kk=kk+1;
end;
S=ss;
D=dd(1,:);

```